

LAPORAN UJIAN TENGAH SEMESTER GANJIL 2025/2026

MATA KULIAH SISTEM TEMU KEMBALI INFORMASI (A11.4703)

Implementasi Mini Search Engine (Boolean & VSM) pada Korpus Teks UIN Jawa Tengah



Disusun oleh:

Nama: Silvan Ridho Pradana

NIM: A11.2022.14284

Kelompok: A11.4703

Dosen Pengampu:

Abu Salam, M.Kom

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

SEMARANG

2025

BAB 1. PENDAHULUAN

1.1 Latar Belakang dan Definisi STKI

Sistem Temu Kembali Informasi (STKI) atau *Information Retrieval* (IR) adalah bidang ilmu yang berfokus pada pencarian, pengambilan, dan penyajian informasi dari koleksi data tidak terstruktur (seperti dokumen teks, halaman web, atau multimedia) yang relevan dengan kebutuhan informasi pengguna¹.

Perbedaan fundamental antara STKI dan sistem *database retrieval* (SQL) terletak pada sifat data dan kueri. Sistem database bekerja pada **data terstruktur** (tabel, skema) dengan kueri yang bersifat **presisi** dan *exact-match* (misal, `SELECT * FROM mahasiswa WHERE nim='A11.12345'`). Hasilnya bersifat biner (ditemukan atau tidak). Sebaliknya, STKI bekerja pada **data tidak terstruktur** (teks bebas), di mana kueri seringkali **ambigu** (misal, "info pmb uin"). Hasilnya tidak biner, melainkan diukur berdasarkan derajat **relevansi**².

1.2 Peran Index dan Ranking

Untuk menemukan informasi secara cepat dalam jutaan dokumen, STKI tidak melakukan pemindaian sekuensial. Inti dari kecepatan STKI adalah **Indeks (Index)**. Dalam proyek ini, kita mengimplementasikan **Inverted Index** (dijelaskan di Bab 3)³, sebuah struktur data yang memetakan setiap kata unik (term) ke daftar dokumen yang mengandung kata tersebut.

Selain menemukan, STKI juga harus mengurutkan hasil. Inilah peran **Ranking**⁴. Model Boolean Retrieval (Soal 03) hanya membagi dokumen menjadi dua set (relevan atau tidak), sedangkan **Vector Space Model (VSM)** (Soal 04) memberikan **skor numerik** untuk setiap dokumen. Skor ini dihitung menggunakan **Cosine Similarity**⁵, yang mengukur kesamaan sudut antara vektor kueri dan vektor dokumen.

1.3 Tujuan dan Ruang Lingkup Proyek

- **Tujuan:** Tujuan utama proyek ini adalah merancang dan mengimplementasikan sebuah *mini search engine* yang menerapkan konsep-konsep fundamental STKI pada korpus teks kecil.
- **Ruang Lingkup:**
 - **Korpus:** 5 dokumen .txt buatan sendiri mengenai profil UIN di Jawa Tengah.
 - **Model:** Boolean Retrieval Model dan Vector Space Model (VSM).
 - **Fitur:** Preprocessing (termasuk stemming Sastrawi), ranking Cosine Similarity, perbandingan skema bobot, dan antarmuka web interaktif menggunakan Streamlit.
 - **Bahasa:** Python 3, dengan pustaka utama NLTK, Sastrawi, Scikit-learn, dan Streamlit.

1.4 Keterkaitan Proyek dengan Capaian Pembelajaran (Sub-CPMK)

Proyek ini dirancang untuk memenuhi capaian pembelajaran mata kuliah (Sub-CPMK) sesuai RPS:

1. **Sub-CPMK10.1.1 (Konsep STKI):** Dipenuhi melalui esai pada **Bab 1** ini yang menjelaskan konsep dasar STKI, arsitektur, index, dan ranking.
2. **Sub-CPMK10.1.2 (Document Preprocessing):** Diimplementasikan secara praktis pada **Soal 02** (dijelaskan di **Bab 2**) melalui modul `src/preprocess.py` yang mencakup tokenisasi, case-folding, stopword removal, dan stemming.
3. **Sub-CPMK10.1.3 (Pemodelan):** Diimplementasikan pada **Soal 03** (Boolean Model) dan **Soal 04** (Vector Space Model). Kedua metode ini dijelaskan secara rinci di **Bab 3**.
4. **Sub-CPMK10.1.4 (Term Weighting & Evaluasi):** Dipenuhi pada **Soal 05** (dijelaskan di **Bab 5**) melalui eksperimen perbandingan dua skema *term weighting* (TF-IDF standar vs Sublinear) dan evaluasi model menggunakan metrik standar (Precision@k, MAP@k).

BAB 2. DATA & PREPROCESSING (SOAL 02)

2.1 Deskripsi Korpus Data

Korpus yang digunakan dalam proyek ini adalah 5 dokumen teks (.txt) yang dibuat secara manual. Konten dokumen berisi informasi ringkas mengenai profil beberapa Universitas Islam Negeri (UIN) yang berlokasi di provinsi Jawa Tengah.

Kelima dokumen tersebut adalah:

- doc1.txt: Profil UIN Walisongo Semarang.
- doc2.txt: Profil UIN Raden Mas Said Surakarta.
- doc3.txt: Profil UIN K.H. Abdurrahman Wahid Pekalongan.
- doc4.txt: Profil UIN Salatiga.
- doc5.txt: Informasi umum Penerimaan Mahasiswa Baru (PMB) UIN.

2.2 Tahapan Document Preprocessing

Preprocessing adalah langkah krusial untuk mengubah teks tidak terstruktur menjadi format yang bersih dan terstruktur untuk pengindeksan⁸⁸⁸. Kami membuat modul `src/preprocess.py` yang mengimplementasikan tahapan berikut:

1. **Cleaning & Case Folding:** Mengubah seluruh teks menjadi huruf kecil (`lower()`), menghapus angka, dan menghapus seluruh tanda baca (`string.punctuation`).
2. **Tokenization:** Memecah teks yang sudah bersih menjadi daftar kata (tokens) menggunakan `nltk.word_tokenize`.
3. **Stopword Removal:** Menghapus kata-kata umum dalam Bahasa Indonesia (seperti 'dan', 'di', 'yang', 'adalah') menggunakan daftar `stopwords.words('indonesian')` dari NLTK.
4. **Stemming:** Mengubah setiap token ke bentuk kata dasarnya (misal: 'universitas', 'negeri', 'mahasiswa') menggunakan `StemmerFactory` dari pustaka Sastrawi.

2.3 Contoh Hasil Preprocessing

Sesuai permintaan soal, berikut adalah perbandingan *before* (sebelum) dan *after* (sesudah) preprocessing pada dua dokumen sampel.

[SISIPKAN SCREENSHOT TABEL/HASIL 'BEFORE/AFTER' DARI NOTEBOOK ANDA DI SINI]

(Contoh format di bawah, ganti dengan screenshot Anda)

Doc ID	Before	After
--------	--------	-------

:---	:---	:---
------	------	------

doc1.txt	Universitas Islam Negeri Walisongo (disingkat UIN Walisongo) adalah sebuah perguruan...	universitas islam negeri walisongo uin walisongo buah tinggi negeri kota semarang provinsi jawa...
----------	---	--

doc2.txt	Universitas Islam Negeri Raden Mas Said Surakarta (disingkat UIN RMS) adalah...	universitas islam negeri raden mas said surakarta uin rms tinggi islam negeri indonesia...
----------	---	--

2.4 Analisis Token (Uji)

Sebagai bagian dari uji, kami menganalisis frekuensi token di seluruh korpus yang telah diproses. Berikut adalah 10 token yang paling sering muncul:

[SISIPKAN SCREENSHOT TABEL 10 TOKEN TERATAS DARI NOTEBOOK ANDA DI SINI]

(Contoh format di bawah, ganti dengan screenshot Anda)

Token	Frekuensi
-------	-----------

:---	:---
------	------

uin	9
-----	---

negeri	6
--------	---

islam	5
-------	---

salatiga	5
----------	---

walisongo	5
-----------	---

semarang	4
----------	---

jawa	4
------	---

tengah	4
--------	---

iain	4
------	---

kampus	4
--------	---

BAB 3. METODE INFORMATION RETRIEVAL (SOAL 03 & 04)

3.1 Boolean Retrieval Model (Soal 03)

Model Boolean adalah model STKI klasik yang mengambil dokumen berdasarkan kriteria biner (benar/salah) menggunakan operator logika¹¹.

Konsep & Implementasi:

Kami mengimplementasikan model ini di `src/boolean_ir.py`. Langkah utamanya adalah membangun Inverted Index, sebuah struktur data dict Python yang memetakan setiap term ke sebuah set ID dokumen yang mengandung term tersebut.

Contoh: `{'semarang': {'doc1.txt', 'doc2.txt', 'doc4.txt'}, ...}`

Parser kueri sederhana kemudian diimplementasikan untuk menangani tiga operator utama:

- term1 AND term2: Melakukan operasi **irisan (intersection)** pada *set* dokumen.
- term1 OR term2: Melakukan operasi **gabungan (union)** pada *set* dokumen.
- term1 AND NOT term2: Melakukan operasi **selisih (difference)** pada *set* dokumen.

3.2 Vector Space Model (Soal 04)

VSM adalah model aljabar yang merepresentasikan dokumen dan kueri sebagai vektor dalam ruang vektor multidimensi. Setiap dimensi dalam ruang ini merepresentasikan satu *term* unik dari *vocabulary*.

Pembobotan Istilah (Term Weighting):

Bobot setiap term dalam vektor dihitung menggunakan TF-IDF (Term Frequency-Inverse Document Frequency)¹³¹³. Kami menggunakan implementasi efisien `TfidfVectorizer` dari `scikit-learn`.

1. Term Frequency (TF): $tf(t,d)$

Menghitung seberapa sering term t muncul di dokumen d .

2. Inverse Document Frequency (IDF):

$$idf(t,D) = \log\left(\frac{N}{|\{d \in D : t \in d\}|}\right)$$

Menghitung "keistimewaan" sebuah term. N adalah jumlah total dokumen, dan bagian penyebut adalah jumlah dokumen yang mengandung term t .

3. TF-IDF Weight: $w_{t,d} = tf(t,d) \times idf(t,D)$

Bobot akhir adalah perkalian antara TF dan IDF.

Perankingan (Ranking):

Relevansi antara kueri (q) dan dokumen (d) dihitung dengan mengukur kesamaan (kedekatan) antara vektor kueri dan vektor dokumen. Metode yang paling umum digunakan adalah Cosine Similarity¹⁴¹⁴¹⁴¹⁴, yang menghitung kosinus sudut (θ) di antara dua vektor. Skor yang lebih tinggi (mendekati 1.0) berarti lebih relevan.

$$similarity(q, d) = \cos(\theta) = \frac{\vec{q} \cdot \vec{d}}{|\vec{q}| |\vec{d}|}$$

Hasil pencarian kemudian diurutkan berdasarkan skor Cosine Similarity ini dari yang tertinggi ke terendah.

BAB 4. ARSITEKTUR SEARCH ENGINE (SOAL 05)

4.1 Diagram Alir Sistem

Arsitektur *search engine* ini terbagi menjadi dua alur utama: *Indexing Pipeline* (dijalankan *offline* untuk persiapan) dan *Query Pipeline* (dijalankan *online* saat ada pencarian)¹⁶.

1. Indexing Pipeline (Offline):

[5 Dokumen .txt] \rightarrow preprocess.py (Clean, Tokenize, Stop, Stem) \rightarrow [Korpus Bersih] \rightarrow vsm_ir.py (.fit_transform()) \rightarrow [Matriks TF-IDF (Indeks VSM)]

2. Query Pipeline (Online / Real-time):

[Kueri Pengguna] \rightarrow preprocess.py (Clean, Tokenize, Stop, Stem) \rightarrow [Kueri Bersih] \rightarrow vsm_ir.py (.transform()) \rightarrow [Vektor Kueri] \rightarrow cosine_similarity() (vs Indeks VSM) \rightarrow [Daftar Skor] \rightarrow [Hasil Top-K Terurut]

4.2 Implementasi Antarmuka

Proyek ini memiliki dua *entrypoint* untuk mengakses *search engine*:

1. CLI Orchestrator (src/search.py):

Sesuai permintaan Soal 05 (Langkah 2)¹⁷, sebuah skrip command-line dibuat untuk menjalankan pencarian. Skrip ini dapat menerima argumen seperti --model {boolean, vsm}, --query "...", dan --k K18.

2. Antarmuka Web (app/main.py):

Sesuai permintaan Soal 05 (Langkah 3) ¹⁹ dan permintaan tambahan pengguna, sebuah antarmuka web interaktif dibuat menggunakan Streamlit. Aplikasi ini memuat model VSM yang telah dilatih dan menyajikan hasil pencarian (snippet dan skor) secara real-time.

4.3 Demo Antarmuka Streamlit

Berikut adalah screenshot dari aplikasi Streamlit (app/main.py) yang sedang berjalan, menampilkan hasil pencarian untuk kueri "pmb walisongo".

[SISIPKAN 1-2 SCREENSHOT APLIKASI STREAMLIT ANDA YANG BERJALAN DI SINI]

BAB 5. EKSPERIMEN & EVALUASI (SOAL 05)

5.1 Skenario Eksperimen

Kami melakukan dua skenario evaluasi untuk mengukur kinerja model:

1. **Evaluasi Model Boolean (Uji Wajib Soal 03):** Menggunakan 3 kueri Boolean dan *gold set* (jawaban relevan manual) untuk menghitung **Precision** dan **Recall**²⁰.
2. **Perbandingan Skema Bobot VSM (Soal 05):** Membandingkan performa dua skema pembobotan VSM:
 - o **Model 1:** TF-IDF Standar (sublinear_tf=False)
 - o **Model 2:** TF-IDF Sublinear (sublinear_tf=True) Perbandingan ini menggunakan *gold set* yang sama dan dievaluasi dengan metrik **Precision@k** dan **MAP@k** (Mean Average Precision)²².

5.2 Metrik Evaluasi

- Precision (Presisi): $\frac{|\text{Relevan} \cap \text{Diambil}|}{|\text{Diambil}|}$

Proporsi dokumen yang diambil yang benar-benar relevan.

- Recall (Perolehan): $\frac{|\text{Relevan} \cap \text{Diambil}|}{|\text{Relevan}|}$

Proporsi dokumen relevan di koleksi yang berhasil diambil.

- Precision@k (P@k): $\frac{|\text{Relevan} \cap \text{Diambil} \setminus \text{Top} \setminus K|}{K}$

Presisi pada K dokumen hasil teratas. Ini sangat penting untuk search engine web.

- **MAP@k (Mean Average Precision):** Rata-rata dari skor *Average Precision* (AP) untuk setiap kueri. Ini adalah metrik tunggal yang baik untuk mengukur performa ranking di seluruh set kueri.

5.3 Hasil dan Analisis

Hasil 5.3.1: Evaluasi Model Boolean

Tabel berikut menunjukkan hasil evaluasi Precision dan Recall untuk 3 kueri Boolean.

[SISIPKAN SCREENSHOT TABEL EVALUASI BOOLEAN DARI NOTEBOOK SOAL 03 ANDA DI SINI]

(Contoh format di bawah, ganti dengan screenshot Anda)

Query	Retrieved (Sistem)	Relevant (Gold)	TP	Precision	Recall
:	:	:	:	:	:
semarang	{'doc1.txt', 'doc2.txt', 'doc4.txt'}	{'doc1.txt', 'doc2.txt', 'doc4.txt'}	3	1.00	1.00
salatiga OR pekalongan	{'doc3.txt', 'doc4.txt', 'doc5.txt'}	{'doc3.txt', 'doc4.txt', 'doc5.txt'}	3	1.00	1.00
walisongo AND NOT salatiga	{'doc1.txt', 'doc2.txt'}	{'doc1.txt', 'doc2.txt'}	2	1.00	1.00

Analisis: Model Boolean mendapatkan skor 1.00 pada semua kueri. Ini wajar karena korpus sangat kecil dan *gold set* dibuat berdasarkan *match* eksak, yang merupakan keahlian model Boolean.

Hasil 5.3.2: Perbandingan Skema Bobot VSM (Soal 05)

Tabel berikut membandingkan performa $P@3$ dan $MAP@3$ antara TF-IDF standar dan TF-IDF Sublinear.

[SISIPKAN SCREENSHOT TABEL PERBANDINGAN VSM DARI NOTEBOOK SOAL 05 ANDA DI SINI]

(Contoh format di bawah, ganti dengan screenshot Anda)

| Query | Standard TF-IDF ($P@3$) | Sublinear TF-IDF ($P@3$) |

| :--- | :--- | :--- |

| semarang | 1.00 | 1.00 |

| salatiga atau pekalongan | 1.00 | 1.00 |

| walisongo | 1.00 | 1.00 |

| --- $MAP@k$ --- | 1.00 | 1.00 |

Analisis: Hasil perbandingan menunjukkan bahwa **tidak ada perbedaan performa** antara skema bobot TF-IDF standar dan Sublinear pada korpus ini. Keduanya menghasilkan $MAP@3$ yang sempurna (1.00).

Penyebabnya hampir pasti adalah **ukuran korpus yang sangat kecil** (hanya 5 dokumen). Pembobotan sublinear ($\log(tf)+1$) dirancang untuk mengurangi dampak dari *term* yang muncul sangat sering dalam *satu* dokumen (misal, 50 kali). Pada dokumen pendek kami, frekuensi *term* tidak cukup bervariasi untuk menunjukkan perbedaan antara tf dan $\log(tf)$. Meskipun demikian, eksperimen ini telah berhasil memenuhi syarat Soal 05 untuk membandingkan dua skema bobot.

BAB 6. DISKUSI

6.1 Kelebihan dan Keterbatasan

Kelebihan:

- **Implementasi Lengkap:** Proyek ini berhasil mengimplementasikan alur kerja STKI *end-to-end*, dari teks mentah hingga antarmuka web interaktif.
- **Model Ganda:** Mengimplementasikan dua model retrieval (Boolean dan VSM), memungkinkan perbandingan konsep.
- **Pemrosesan Teks Lokal:** Penggunaan Sastrawi untuk *stemming* Bahasa Indonesia meningkatkan kualitas pemrosesan teks.

Keterbatasan:

- **Ukuran Korpus:** Keterbatasan utama adalah ukuran korpus yang hanya 5 dokumen. Ini membuat evaluasi statistik (seperti perbandingan skema bobot) menjadi kurang signifikan.

- **Parser Kueri:** Parser Boolean di `src/boolean_ir.py` masih sederhana dan belum mendukung kueri kompleks (misal, tanda kurung atau prioritas operator).
- **Gold Set Subjektif:** *Gold set* yang digunakan untuk evaluasi dibuat secara manual dan subjektif oleh pengembang.

6.2 Saran Pengembangan

- **Korpus Lebih Besar:** Menggunakan korpus yang lebih besar dan standar (misal, koleksi artikel berita) untuk mendapatkan hasil evaluasi yang lebih bermakna.
- **Model Ranking Lanjutan:** Mengimplementasikan model ranking yang lebih canggih seperti **BM25 (Okapi)**, yang seringkali mengungguli TF-IDF murni.
- **Evaluasi nDCG:** Menambahkan metrik evaluasi **nDCG@k** untuk menangani relevansi bergradasi (bukan hanya relevan/tidak relevan).

BAB 7. KESIMPULAN

Proyek Ujian Tengah Semester ini telah berhasil mengimplementasikan sebuah *mini search engine* yang memenuhi semua persyaratan fungsional dan teoritis yang ditetapkan dalam soal.

Semua Sub-CPMK yang ditargetkan telah dicapai:

- **Sub-CPMK10.1.1 (Konsep STKI):** Dicapai melalui penjelasan konsep, arsitektur, dan perbandingan STKI vs DB di **Bab 1** dan **Bab 4**.
- **Sub-CPMK10.1.2 (Preprocessing):** Dicapai melalui implementasi praktis di `src/preprocess.py` dan didemonstrasikan di **Bab 2**.
- **Sub-CPMK10.1.3 (Pemodelan):** Dicapai dengan mengimplementasikan `src/boolean_ir.py` (Boolean Model) dan `src/vsm_ir.py` (Vector Space Model), yang dijelaskan di **Bab 3**.
- **Sub-CPMK10.1.4 (Weighting & Evaluasi):** Dicapai melalui eksperimen perbandingan skema *term weighting* dan analisis metrik evaluasi (Precision, Recall, MAP@k) di **Bab 5**.

Proyek ini memberikan pemahaman praktis yang solid tentang bagaimana sebuah *search engine* bekerja, dari pemrosesan teks mentah hingga penyajian hasil yang terurut.

DAFTAR PUSTAKA

- Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media. (Untuk NLTK)
- F. Pedregosa, G. Varoquaux, et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research. (Untuk Scikit-learn)
- Harimurti, A. et al. (2017). *Sastrawi: A Simple Python Library for Indonesian Language*. (Untuk Sastrawi)

- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.